

```
import fitz # PyMuPDF
import subprocess
import pytesseract
from PIL import Image
import io
import os
import shutil

# 📢 CHEMINS TESSERACT : UTILISEZ CEUX QUE VOUS AVEZ VÉRIFIÉS 📢
TESSERACT_PATH = r"C:\Users\HP ELITE BOOK\AppData\Local\Programs\Tesseract-OCR\tesseract.exe"
TESSDATA_DIR = r"C:\Users\HP ELITE BOOK\AppData\Local\Programs\Tesseract-OCR\tessdata"

# Configuration de L'environnement Python pour Tesseract
pytesseract.pytesseract.tesseract_cmd = TESSERACT_PATH
# Définit la variable d'environnement TESSDATA_PREFIX (plus fiable)
os.environ['TESSDATA_PREFIX'] = TESSDATA_DIR

def generate_ocr_split(input_pdf_path, output_split_dir="ocr_split_pages"):
    """
    Traite le PDF page par page, effectue l'OCR et sauvegarde chaque page
    individuellement dans un dossier.
    """

    TESSERACT_LANG = "fra"

    try:
        # Créer le dossier de sortie pour les pages splittées si nécessaire
        if not os.path.exists(output_split_dir):
            os.makedirs(output_split_dir)
            print(f"Création du dossier de sortie : '{output_split_dir}'")
```