

```
import fitz # PyMuPDF
import subprocess
import pytesseract
from PIL import Image
import io
import os
import shutil

# 📢 CHEMINS TESSERACT : UTILISEZ CEUX QUE VOUS AVEZ VÉRIFIÉS 📢
TESSERACT_PATH = r"C:\Users\HP ELITE BOOK\AppData\Local\Programs\Tesseract-OCR\tesseract.exe"
TESSDATA_DIR = r"C:\Users\HP ELITE BOOK\AppData\Local\Programs\Tesseract-OCR\tessdata"

# Configuration de L'environnement Python pour Tesseract
pytesseract.pytesseract.tesseract_cmd = TESSERACT_PATH
# Définit la variable d'environnement TESSDATA_PREFIX (plus fiable)
os.environ['TESSDATA_PREFIX'] = TESSDATA_DIR

def generate_ocr_split(input_pdf_path, output_split_dir="ocr_split_pages"):
    """
    Traite le PDF page par page, effectue l'OCR et sauvegarde chaque page
    individuellement dans un dossier.
    """

    TESSERACT_LANG = "fra"

    try:
        # Créer le dossier de sortie pour les pages splittées si nécessaire
        if not os.path.exists(output_split_dir):
            os.makedirs(output_split_dir)
            print(f"Création du dossier de sortie : '{output_split_dir}'")
```

```
doc = fitz.open(input_pdf_path)
print(f"Démarrage de l'OCR sur {doc.page_count} pages...")

# Nous n'avons plus besoin de temp_ocr_files car il n'y a pas de fusion

for i in range(doc.page_count):
    page = doc.load_page(i)

    # 1. Conversion de la page en image PNG (haute résolution)
    pix = page.get_pixmap(dpi=300)
    temp_image_file = f"temp_ocr_page_{i+1}.png"
    pix.save(temp_image_file)

    # 2. Définition des chemins de sortie
    temp_pdf_file = f"temp_ocr_page_{i+1}.pdf"
    split_output_file = os.path.join(output_split_dir, f"ocr_page_{i+1}.pdf")

    # 3. Exécution de Tesseract (génère temp_pdf_file)
    command = [
        TESSERACT_PATH,
        temp_image_file,
        temp_pdf_file[:-4], # Fichier de sortie temporaire (nom sans extension .pdf)
        '-l', TESSERACT_LANG,
        'pdf'
    ]

    subprocess.run(command, check=True, capture_output=True, text=True)

    # 4. Déplacement du fichier OCR final vers le dossier de split
    shutil.move(temp_pdf_file, split_output_file)
```

```

        # 5. Nettoyage
        os.remove(temp_image_file)

        print(f"Page {i+1} : OCR terminé et enregistré dans '{split_output_file}'")

    doc.close()

    print("\n☑ Succès : Toutes les pages OCR ont été enregistrées individuellement.")
    return output_split_dir

except subprocess.CalledProcessError as e:
    print(f"\nERREUR TESSERACT: Tesseract a échoué avec le code {e.returncode}. Sortie : {e.stderr}")
    return None
except Exception as e:
    print(f"\nERREUR: Une erreur est survenue pendant l'OCR: {e}")
    return None

# ----- EXÉCUTION DU SCRIPT -----
if __name__ == "__main__":
    input_pdf = "relevé_oct_nov.pdf"
    # Appel de la nouvelle fonction qui ne fait pas de fusion
    result_dir = generate_ocr_split(input_pdf)

    if result_dir:
        print(f"\nLe dossier contenant les pages OCR est : {result_dir}")

```